ANÁLISIS Y CIENCIA DE DATOS · PARTE INDIVIDUAL

Grafo de colaboración de Samuel L. Jackson

Un grafo de colaboración es un kernel: construirlo con TMDB y leerlo con el espectro de su Laplaciano

Rodolfo Flores
Facultad de Ingeniería, Universidad del Istmo de Guatemala
6 de noviembre de 2026

$$A = BB^T$$

Un grafo de colaboración es un kernel

$$B_{am} = \mathbf{1}\{\text{el actor } a \text{ sale en la película } m\}$$

$$A = BB^{\top} \ \text{(fuera de la diagonal)}, \qquad A_{ab} = \sum_{m} B_{am} B_{bm}$$

$$S = \frac{1}{T}\sum_{t=1}^{T} Z_t \,\mathrm{diag}\left(\frac{1}{|L|}\right) Z_t^{\top} \quad \longleftrightarrow \quad A = BB^{\top}$$

BOSQUE (GRUPAL)

Filas de entrenamiento que caen en la misma hoja de un árbol.

GRAFO (INDIVIDUAL)

Actores que salen en la misma película.

ESPECTRO

Igual que Sudjianto con el bosque: buscar regiones donde el kernel conecta poco.

Del API de TMDB a 377 actores

108
películas cuentan para Jackson (1975–2025, order < 5)

377
actores (nodos) tras el paso (b)

2 666
aristas; peso total 2 984 películas compartidas

371
grado de la semilla; le sigue Bruce Willis con 54

PASOS

- limit = 5, ventana 1975-01-01 a 2025-12-31
- (a) la semilla; (b) elenco con order < 5 de cada película que cuenta para ella
- (c) créditos de cada nodo: una arista por película y por pareja, sin nodos nuevos
- Sin documentales (género 99) ni papeles de sí mismo (Himself / Herself / Self)

ARISTAS MÁS PESADAS

Pareja	Películas
Vin Diesel – Michelle Rodriguez	8
Eddie Murphy – Antonio Banderas	8
Chris Evans – Scarlett Johansson	7
Bruce Willis – Samuel L. Jackson	5

Dos clases: Graph y TMDBAPIUtils

GRAPH (GRAFO.PY)

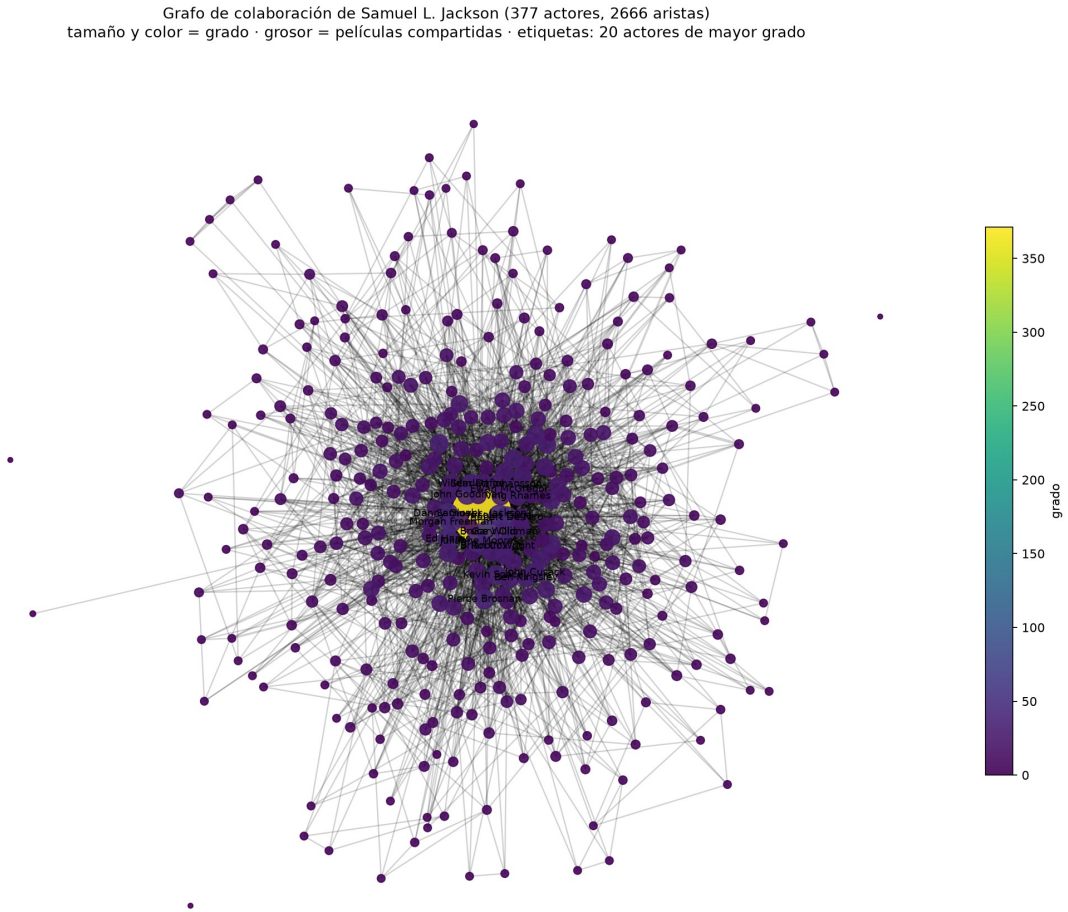
- add_node((id, nombre)): solo si el id no existe
- add_edge(a, b): clave (min, max), peso + 1 si ya existe
- total_nodes(), total_edges()
- max_degree_nodes(): {id: grado} con todos los empatados
- adjacency(): (A con pesos, lista de id en el orden de las filas)

TMDBAPIUTILS (TMDB_UTILS.PY)

- get_movie_cast(movie_id, limit, exclude_ids): 0 ≤ order ≤ limit − 1
- get_movie_credits_for_person(person_id, start_date, end_date): id, title, release_date, order
- Filtro de fechas propio (YYYY-MM-DD), sin documentales ni papeles de sí mismo
- Cache: cada respuesta es un JSON en cache/ (486 archivos)
- La API key se lee de TMDB_API_KEY; nunca va al repositorio

Prueba: 3 nodos, (1,2) dos veces y (2,1) cuenta como la misma arista → $A_{12} = 2$, A simétrica.

La semilla en el centro, todos a un paso



MAYOR GRADO

Actor	Grado	Ponderado
Samuel L. Jackson	371	415
Bruce Willis	54	71
Robert De Niro	45	56
Nicolas Cage	44	59
Julianne Moore	43	47
Danny Glover	42	48
Morgan Freeman	41	50

Laplaciano y Laplaciano normalizado

$$L = D - A, \qquad D = \operatorname{diag}(d_1, \ldots, d_n), \qquad d_a = \sum_b A_{ab}$$

$$L_{\text{sym}} = I - D^{-1/2} A D^{-1/2}$$

$$v^{\top} L v = \frac{1}{2} \sum_{a,\, b} A_{ab} (v_a - v_b)^2 \;\geq\; 0$$

$$\#\,\text{componentes} = \#\left\{k : \;\lambda_k(L_{\text{sym}}) < 10^{-8}\right\}$$

NODOS AISLADOS (SIN VECINOS)

$$d_a = 0 : \quad D_{aa}^{-1/2} := 0 \;\; \text{y} \;\; L_{\text{sym}} = D^{-1/2} L D^{-1/2} \;\Rightarrow\; \lambda = 0 \text{ para el aislado}$$

Tres actores aislados, incluso con la semilla

Grafo	Nodos	Aislados	BFS	λ<1e-8 ingenuo	λ<1e-8 corregido	networkx
Con semilla	377	3	4	**1**	4	4
Sin semilla	376	3	5	**2**	5	5

3

aislados: Kendrick Lamar, Serena Williams, Mustard (papel de sí mismos)

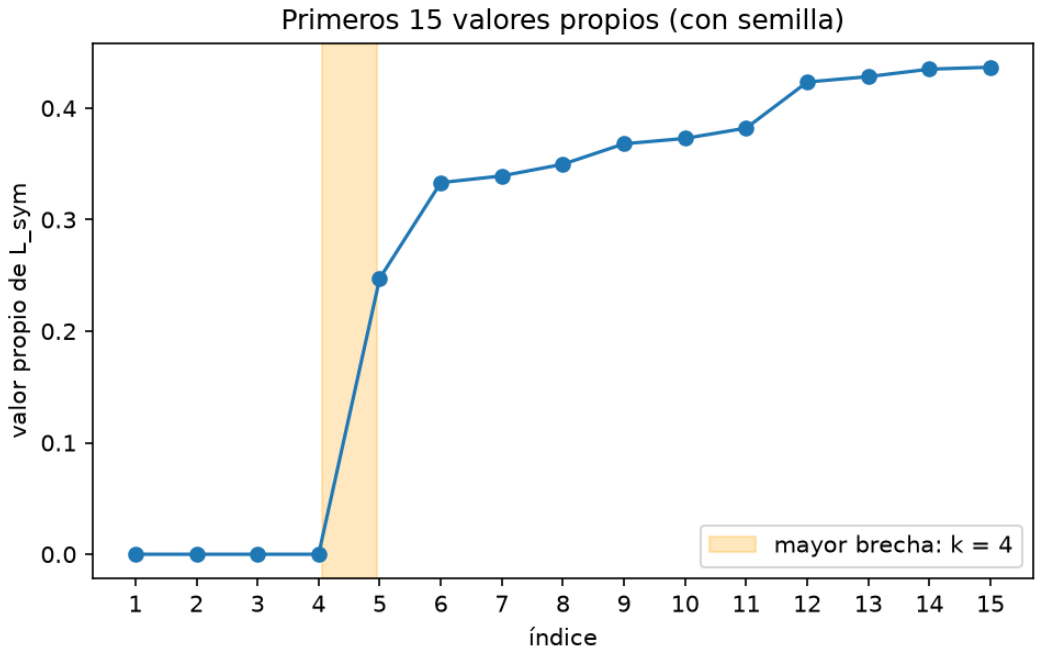
−3

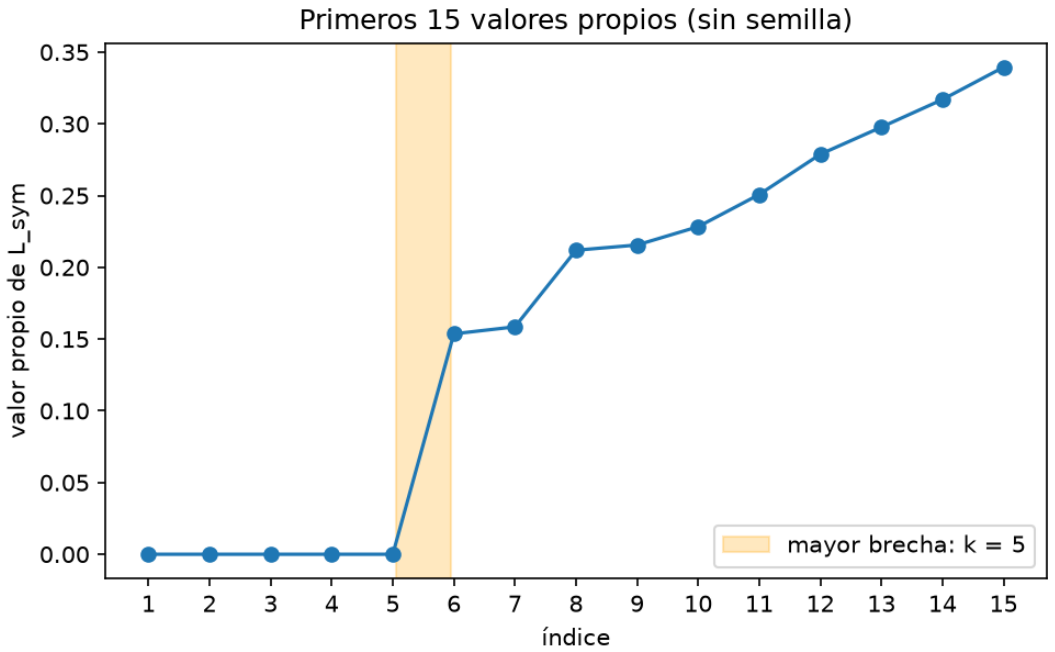
lo que pierde el conteo ingenuo: exactamente los aislados

4

italianos de The Red Violin forman su propia componente sin la semilla

$\lambda_2 = 0$ con la semilla; 0.247 en su componente





$$k^* = \arg\max_{1 \le k \le 14} (\lambda_{k+1} - \lambda_k)$$

- Con semilla: $\lambda_1 = \lambda_2 = \lambda_3 = \lambda_4 = 0 \rightarrow k = 4$ (tres aislados + resto)
- Componente de la semilla (374): $\lambda_2 = 0.247$; siguiente brecha en $k = 2$
- La semilla tiene grado ponderado 415: en L_sym sus aristas pesan poco y los grupos que solo se unen por ella casi se separan

Comunidades: un país, una época, una industria

$$U = [v_1, \ldots, v_k] \in \mathbb{R}^{n \times k}, \quad u_a \leftarrow \frac{u_a}{\|u_a\|}, \quad k-\text{means sobre las filas } u_a$$

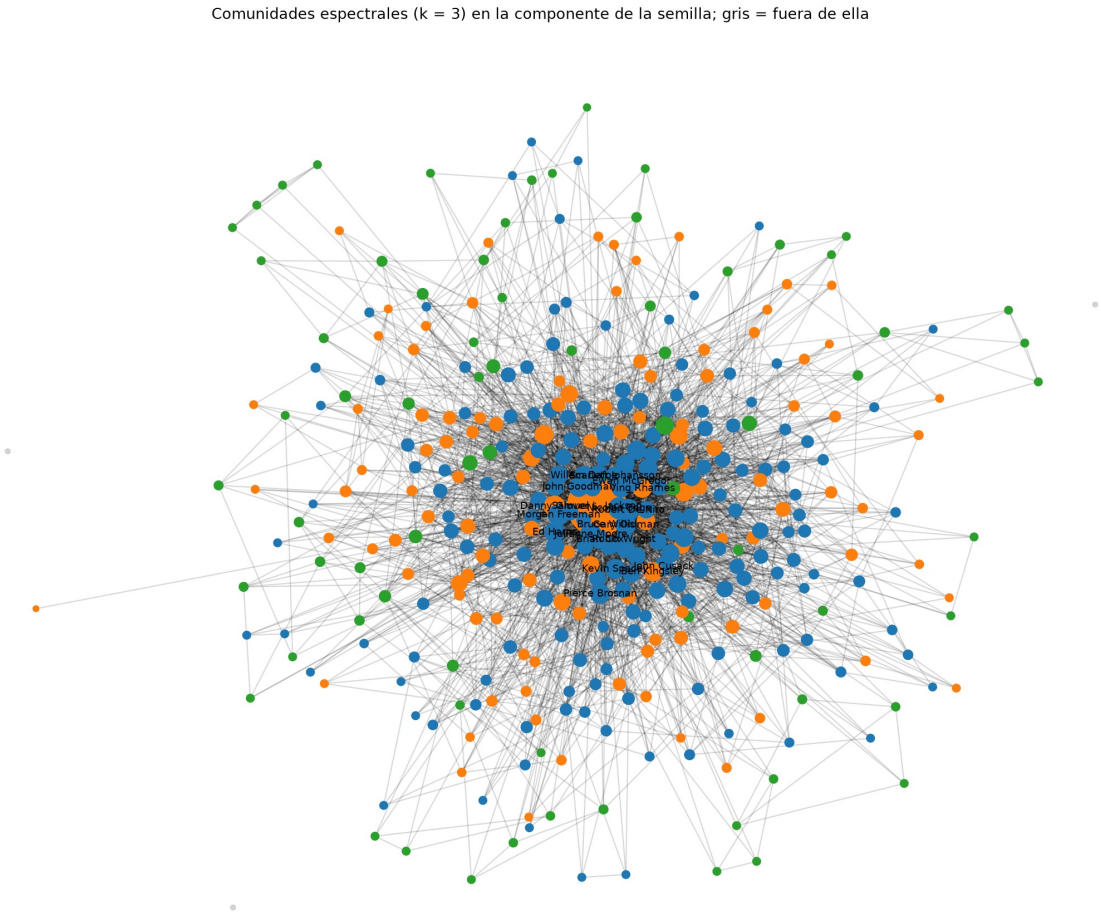
K = 2 (MAYOR BRECHA CON K ≥ 2): UN PAÍS

n	Actores de mayor grado	Películas más repetidas
4	Carlo Cecchi, Irene Grazioli, Anita Laurenzi	The Red Violin (1998) ×4

K = 3: ÉPOCAS E INDUSTRIAS

n	Actores de mayor grado	Películas más repetidas
187	Robert De Niro, Nicolas Cage, Julianne Moore	Spider-Man: Homecoming · Snakes on a Plane · Hero
115	Samuel L. Jackson, Bruce Willis, Danny Glover	Pulp Fiction · The Great White Hype · Against the Wall
72	Wesley Snipes, Giancarlo Esposito, Lynn Whitfield	Coach Carter · Menace II Society · Fresh

Las tres comunidades sobre el grafo



- **Azul** · Hollywood comercial 2000–2010 (187)
- **Naranja** · núcleo de Jackson en los 90 (115)
- **Verde** · cine afroamericano de los 90 y 2000 (72)
- **Gris** · aislados por la regla de “sí mismo”

El corte separa al cine afroamericano del comercial

$$L_{\text{sym}} v_2 = \lambda_2 v_2, \qquad S^+ = \{a : \; v_{2a} \geq 0\}, \quad S^- = \{a : \; v_{2a} < 0\}$$

318

lado + : Willis, De Niro, Cage, Moore, Freeman, Ed Harris

51

lado − : Glover, Rhames, Snipes, Angela Bassett, Perlman, Schreiber

15 %

de las aristas cruzan (344 de 2 289); $\lambda_2 = 0.154$

PELÍCULAS DE CADA LADO

- + : Lucky Number Slevin, Spider-Man: Homecoming, The Protégé, Snakes on a Plane
- − : Fresh, Chi-Raq, Spike & Co.: Do It a Cappella, Monkeybone, Kiss of Death

ARISTAS QUE CRUZAN (MÁS PESADAS)

- Eddie Murphy – Antonio Banderas (8)
- Jada Pinkett Smith – Chris Rock (5)
- Bruce Willis – Ving Rhames (2)

Grado contra vector propio: 3 de 5 en común

$$A\,v = \lambda_{\max}\,v, \qquad c_a = \frac{|v_a|}{\max_b |v_b|}$$

#	Mayor grado	Mayor centralidad de vector propio
1	Samuel L. Jackson (371)	Samuel L. Jackson (1.000)
2	Bruce Willis (54)	Bruce Willis (0.372)
3	Robert De Niro (45)	Nicolas Cage (0.255)
4	Nicolas Cage (44)	**John Travolta (0.229)**
5	Julianne Moore (43)	**Morgan Freeman (0.223)**

QUÉ MIDE CADA UNA

- Grado: alcance directo, cuántos coprotagonistas distintos
- Vector propio: importancia de los contactos, usando pesos (películas repetidas)
- Verificado contra networkx en la componente principal (dif. $9{\cdot}10^{-16}$)

BB^{T} coincide con A; su diagonal cuenta películas

$$A = BB^{\mathsf{T}} \quad \text{(fuera de la diagonal)}, \qquad A_{ab} = \sum_m B_{am} B_{bm}$$

$$(BB^{\mathsf{T}})_{aa} = \sum_m B_{am}^2 = \#\,\text{películas que cuentan para } a$$

377 × 10 334

dimensiones de B (actores × películas)

$BB^{\mathsf{T}} = A$

fuera de la diagonal: verificado exactamente

142

diagonal más grande: Corbin Bernsen (Glover 127, Jackson 108)

Analogía: en el bosque, dos filas se parecen si comparten hojas; aquí, dos actores si comparten películas. El bosque divide entre |hoja| para que el voto sume 1; aquí L_sym descuenta a los actores con muchas películas. El espectro de ambos kernels señala dónde la conexión (la evidencia) es débil.

CONCLUSIONES

Gracias

- El grafo es un kernel: $A = BB^T$ cuenta películas compartidas, igual que el bosque cuenta hojas compartidas
- La regla de excluir papeles de sí mismo rompe la conexidad: 3 aislados y $\lambda_2 = 0$
- El espectro encuentra comunidades reales: un país (The Red Violin), épocas e industrias
- Grado y vector propio miden cosas distintas: alcance contra importancia de los contactos

